

The background is a dark blue space filled with a network of glowing spheres and thin white lines. The spheres are of various sizes and colors, including gold, silver, and blue. They are interconnected by thin white lines, creating a complex, web-like structure. The lighting is soft and focused on the spheres, giving them a three-dimensional appearance.

Future of Fragrance

Propensity Modeling im Marketing

Kendric Scoles
FHNW Olten – Machine Learning Project
BSc Business AI
Dezember 2025

Agenda

Geschäftsproblem und Zielsetzung



Methodisches Vorgehen



Technische Werkzeuge und Pipeline



Ergebnisse und Metriken



Herausforderungen und Erkenntnisse



Das Geschäftsproblem

Wie identifizieren wir die Kunden mit der höchsten Kaufwahrscheinlichkeit?

Ausgangslage:

- E-Commerce Unternehmen verfügen über umfangreiche Verhaltensdaten
- Marketingbudgets sind begrenzt
- Klassische Kampagnen erreichen oft die falschen Zielgruppen

Die Herausforderung:

- Nur ca. 10% der Kunden kaufen tatsächlich Parfümprodukte
- Zufälliges Targeting verschwendet das Budget
- Gefragt ist eine datengetriebene Priorisierung

Der Lösungsansatz

- Propensity-Modell zur Vorhersage der Kaufwahrscheinlichkeit
- Ranking der Kunden nach Kaufneigung
- Fokussierung auf die vielversprechendsten Segmente

Projektziele & Rahmenbedingungen

Geschäftsziel:

- Prognose der individuellen Kaufwahrscheinlichkeit
- Ranking nach Propensity-Score
- Grundlage für zielgerichtete Kampagnensteuerung

Technisches Ziel:

- Reproduzierbare End-to-End Pipeline
- Modelltraining mit XGBoost
- Automatisierte Evaluation und Fairness-Prüfung

Rahmenbedingungen:

- Keine echten Kundendaten
- Vollständig generierter Datensatz
- Realistische Verhaltensmuster nachgebildet

Feature	Beschreibung	Typ
views_7d	Seitenaufrufe in 7 Tagen	Numerisch
add_to_cart_30d	Warenkorbaktionen (30 Tage)	Numerisch
orders_12m	Bestellungen (12 Monate)	Numerisch
avg_price_viewed	Ø angesehener Produktpreis	Numerisch
brand_diversity	Markenvielfalt	Numerisch
days_since_last_purchase	Tage seit letztem Kauf	Numerisch
campaign_clicks	Kampagnenklicks	Numerisch
age_group	Altersgruppe	Kategorisch
region	Region	Kategorisch

Der synthetische Datensatz

- Zielgrösse: bought_fragrance (0/1) – Kauft Parfüm? Ca. 10% Positiv
- Datensatzgrösse: rund 20'000 Zeilen

Methodisches Vorgehen – Die Pipeline

1. Datengenerierung

Src/data_prep.py

-> Synthetische Daten

2. Training

Src/train.py

-> XGBoost Modell

3. Vorhersage

Src/make_predictions.py

-> Propensity Scores

4. Training

Src/train.py

-> XGBoost Modell

5. Visualisierung

Src/generate_pngs.py

-> Kurven & SHAP

6. Fairness

Src/fairness_eval.py

-> Bias-Analyse

Modellarchitektur

Numerische Features

- StandardScaler
- views_7d, add_to_cart_30d, orders_12m, avg_price_viewed, brand_diversity, days_since_last_purchase, campaign_clicks

XGBoost Classifier

- 600 Bäume
- Lernrate: 0.05
- Maximale Tiefe: 5
- Subsampling: 90%
- Scale_pos_weight: Automatisch (+/-)

Vorhersage

- $P(\text{bought_fragrance} = 1)$
- Ranking Nach Score
- Dezil-Zuordnung

0.90

ROC-AUC

Diskriminierungsfähigkeit

0.85

PR-AUC

Präzision bei Imbalance

4.12x

Lift @ 10 %

Targeting-Effizienz

3.88x


Lift @ 20 %

Erweiterte Reichweite

Python 3.11 | XGBoost | SHAP | scikit-learn | GitHub Actions | Docker

Werkzeuge und Ergebnisse

Was bedeutet Lift 4.12x?



Beispielrechnung

10'000 Kund:innen - 10 % Käufer = 1'000 echte Käufer

Budget: 1'000 Kontakte

Zufällig


~100 Käufer (10 %)

Modellbasiert


~410 Käufer (41 %)

4× mehr Effizienz bei gleichem Budget

Zufall	0.50
Logistische Regression	0.78
XGBoost	0.90



PR-Kurve (AP = 0.85)



Lift-Kurve


Dezil-Highlights

Top 10 %	79 Käufer
Top 20 %	149 Käufer
Rest	43 Käufer

Top 20 % = 78 % aller Käufer

Detaillierte Evaluation


Interpretierbarkeit und Fairness



1. days_since_last_purchase
2. avg_price_viewed
3. add_to_cart_30d
4. views_7d

1 Top-5 Einflussfaktoren

Fairness-Analyse



- Selection Rate Gap < 5 %
- TPR Gap < 5 %
- PPV Gap < 5 %

✓ Keine signifikante Altersdiskriminierung

Herausforderungen

Klassenungleichheit (10 % positiv)
scale_pos_weight + PR-AUC

Synthetische Daten

Realistische Annahmen + Dokumentation

Reproduzierbarkeit

CI/CD + Docker + Makefile

Zentrale Erkenntnisse

XGBoost + Feature Engineering =
starkes Propensity-Scoring

PR-AUC und Lift sind unverzichtbar
bei Imbalance

SHAP schafft Vertrauen
durch Transparenz



Demo

```
$ make run-all
```

- Training: XGBoost
- Predictions: 800 rows
- Metrics: AUC = 0.90
- Visualizations: 7 PNGs
- Fairness: OK

Ausblick

Kurzfristig (1-3 Monate)

Echte Daten integrieren, A/B-Tests starten

Mittelfristig (3-6 Monate)

Hyperparameter-Tuning, Modellvergleich

Langfristig (6-12 Monate)

Multi-Produkt-Modelle, CRM-Integration

Zusammenfassung

Zusammenfassung



Ziel erreicht: Propensity-Modell entwickelt



Starke Performance: AUC 0.90 | Lift 4.12×



Transparenz: SHAP-basierte Interpretation



Fairness: OK

Vielen Dank für Ihre Aufmerksamkeit
Fragen?

Kendric Scoles

BSc Business AI | FHNW Olten

github.com/kendricsscoles/ml-future-fragrance

Ausblick

Kurzfristig (1-3 Monate)

Echte Daten integrieren, A/B-Tests starten

Mittelfristig (3-6 Monate)

Hyperparameter-Tuning, Modellvergleich

Langfristig (6-12 Monate)

Multi-Produkt-Modelle, CRM-Integration